

Introducción a Pandas aplicado a Ingeniería de Datos


Introducción

En **ingeniería de datos**, una **gran parte del trabajo consiste en recibir datos, inspeccionarlos, limpiarlos, transformarlos y prepararlos**, para posteriormente ser utilizados en otros sistemas o incluso otras áreas.

En clases anteriores trabajamos con archivos utilizando JavaScript y Python, donde construimos pequeños **pipelines de datos de forma manual**. Sin embargo, cuando la cantidad de registros y columnas comienza a crecer, trabajar únicamente con listas, diccionarios y ciclos for, se vuelve insostenible.

Aquí es donde aparece **Pandas**, una biblioteca de Python, **escrita en C y CPython**, **especializada en manipulación y análisis de datos estructurados**. **Permite** trabajar **cómodamente** con información proveniente de archivos **CSV, JSON, EXCEL**, bases de datos y otras fuentes como **APIs**.

En un **pipeline** de datos, pandas puede intervenir principalmente en las etapas de:



Algo a tener en cuenta es que **Pandas no reemplaza a Python**, de hecho, es una herramienta construida sobre Python, que **nos proporciona estructuras especialmente diseñadas para trabajar con datos**.

¿Por qué Pandas?

Supongamos que recibamos información de ventas:

Python

```
ventas = [  
    { "producto": "Notebook", "precio": 850000, "cantidad": 2 },  
    { "producto": "Mouse", "precio": 15000, "cantidad": 5 },  
    { "producto": "Teclado", "precio": 35000, "cantidad": 3 }  
]
```

Si quisiéramos calcular por ejemplo, el importe total de cada venta, utilizando únicamente Python, tendríamos que hacer algo como esto:

Python

```
for venta in ventas:  
    venta["total"] = venta["precio"] * venta["cantidad"]
```

Que obviamente, no decimos que este mal, de hecho, va a funcionar perfectamente. Pero, imaginemos que estamos frente a un archivo con 2 millones de registros, con valores faltantes, registros duplicados, diferentes formatos de fechas. Ahora se complicó, ¿no? Podríamos intentar resolverlo con Python, y podríamos lograrlo, pero nuestro código crecerá tanto que llegará a un punto que será insostenible.

Con Pandas, podríamos hacer simplemente esto:

Python

```
df["total"] = df["precio"] * df["cantidad"]
```

Con solamente esta línea, estamos creando una columna llamada “total”, y estamos calculando el total de cada **fila** de nuestro **Dataframe**.

Series y DataFrames

Pandas introduce a python, dos nuevos tipos y esos son las **Series** y los **DataFrames**.

Una Serie es una estructura de datos unidimensional que almacena una secuencia de valores y un conjunto de etiquetas de índice asociadas a cada valor. Podemos imaginar a una serie como una sola columna de una tabla.

Un DataFrame en cambio, representa una estructura de datos, conformada por **filas y columnas**, de manera muy similar a por ejemplo: un tabla SQL o una hoja de cálculo de excel.

Instalación de Pandas

1. Creación de un entorno virtual: Antes de empezar a trabajar, es importante crear un entorno virtual de Python.

Shell

```
# para windows  
uv venv env && env\Scripts\activate
```

o

Shell

```
# para linux y macos  
uv venv env && env/bin/activate
```

2. Instalamos pandas utilizando uv y pip

Shell

```
uv pip install pandas
```

3. Importación dentro de un .py o un .ipynb

Python

```
import pandas as pd
```

Por convención, la comunidad de Python utiliza el alias “pd”, pero, sin el alias, podríamos utilizar directamente el nombre de la librería, pandas.

Python

```
import pandas
```

Y sería igual de funcional.

Estructuras fundamentales de Pandas

Como mencionamos más arriba, pandas posee dos estructuras principales:

- Series
- DataFrames

1. Series

Una series, representa una estructura unidimensional. La podemos crear con la c `pd.Series()`

Python

```
import pandas
```

```
precios = pd.Series([  
    1500,  
    2000,
```

```
3090,  
4000  
)  
print(precios)
```

Deberíamos obtener una salida como esta:

```
[2] ✓ 0 s ▶ import pandas  
  
precios = pd.Series([  
    1500,  
    2000,  
    3090,  
    4000  
)  
print(precios)
```

...	0	1500
	1	2000
	2	3090
	3	4000
	dtype: int64	

Pandas asigna un **índice** a cada elemento automáticamente.

2. DataFrames

El dataframe podemos verlo representado de la siguiente forma:

```
Python  
import pandas as pd  
  
datos = {  
    "producto": [  
        "Notebook",  
        "Mouse",  
        "Teclado"  
    ],
```

```
"precio": [
    850000,
    15000,
    35000
],
"cantidad": [
    2,
    5,
    3
]
}

df = pd.DataFrame(datos)
print(df)
```

Deberíamos obtener un resultado como este:

```
[3]
✓ 0s
datos = {
    "producto": [
        "Notebook",
        "Mouse",
        "Teclado"
    ],
    "precio": [
        850000,
        15000,
        35000
    ],
    "cantidad": [
        2,
        5,
        3
    ]
}

df = pd.DataFrame(datos)
print(df)
```

	producto	precio	cantidad
0	Notebook	850000	2
1	Mouse	15000	5
2	Teclado	35000	3

al igual que las series se identifican en índices, pero con la distinción que dentro de nuestro dataframe podemos trabajar con series(filas) y columnas.


RECORDAR:

A la hora de querer o buscar crear en implementar nuevas columnas, es importante inferir en repetir la misma estructura, es posible que lo que suele fallar sean problemas en comas, uso de () o [].

Como podemos ver, pandas creó una columna por cada key de nuestro diccionario y agregó sus valores en cada columna correspondiente, y ahora estas conforman también filas.

Pandas dentro de un Pipeline de Datos

Podemos pensar en el trabajo de pandas mediante una secuencia:



Extract: Extraemos el contenido de un archivo, base de datos o incluso de una API.

DataFrame: Con pandas convertimos los datos en una estructura de filas y columnas.

Inspect: Realizamos un análisis para verificar los datos.


Clean: Limpiamos los valores duplicados, nulos o inválidos.

Transform: Transformamos los datos, aplicamos algunas estandarizaciones.

Validar: Validamos de que todo haya salido correctamente.

Load: Guardamos los datos limpios y los dejamos accesibles.

Este proceso se aproxima bastante al concepto de **ETL**.



Ingesta de Datos

Una de las ventajas de Pandas es que puede cargar información desde diferentes fuentes:

1. CSV: Archivos de texto separados por comas o por puntos y comas. En pandas tenemos un método llamado **read_csv()** y lo podemos utilizar de la siguiente forma:

```
Python
import pandas as pd

df = pd.read_csv("path del archivo")
```

2. JSON: Archivos separados por keys y values. En pandas, podemos utilizar un método llamado **read_json()**:

```
Python
import pandas as pd

df = pd.read_json("path del archivo")
```



3. Excel: Normalmente las hojas de cálculo de excel, están en el siguiente formato **.xlsx**. En pandas tenemos el método **read_excel()**

Python

```
import pandas as pd
```

```
df = pd.read_excel("path del archivo")
```

Aunque la fuente de datos sea diferente, después de cargar los datos, normalmente terminaremos trabajando con un **DataFrame**. Esto nos permite desacoplar parcialmente nuestro procesamiento del formato original de los datos.



Procesamiento y preparación de datos con Pandas

Antes de modificar los datos debemos conocerlos, y es que uno de los errores más comunes es comenzar a transformar el dataset sin entender primero su estructura.

1. Acceder a las primeras filas: Lo podemos hacer fácilmente con el método **head()**

```
Python  
df.head()
```

Por defecto nos mostrará las primeras 5 filas. Podemos pasarle como parámetro la cantidad de filas que queremos observar.

```
Python  
df.head(10)
```

2. Acceder a las últimas filas: Podemos utilizar el método **tail()**, que similar a head, nos devuelve por defecto, las últimas 5 filas.

```
Python  
df.tail()
```

Por defecto nos mostrará las últimas 5 filas. Podemos pasarle como parámetro la cantidad de filas que queremos observar.

```
Python  
df.tail(10)
```

3. Dimensiones: Con el atributo **shape** podemos obtener las dimensiones de nuestro dataframe:

```
Python  
df.shape  
  
# Obtendremos una salida similar a: (1000, 8)  
# que significa: 1000 filas y 8 columnas.
```

4. Obtener las columnas: podemos acceder a los nombres de las columnas con el atributo **columns**

```
Python
df.columns

# Obtendrás una salida como esta:

Index([ 'id', 'producto', 'precio', 'cantidad', 'fecha' ],
      dtype='object')
```

Esto resulta especialmente útil cuando recibimos un dataset que no conocemos.

5. Tipos de datos: con el atributo **dtypes** podemos obtener los tipos de datos correspondientes a cada columna:

```
Python
df.dtypes

# Obtendrás una salida como esta:

Por ejemplo:
id          int64
producto    object
precio      float64
cantidad    int64
fecha       object
```

Conocer los tipos es importante porque los datos provenientes de archivos externos no siempre son interpretados correctamente.

Por ejemplo, una fecha puede ser interpretada simplemente como texto:
"2026-08-26"

6. Información General de un Dataframe: Podemos obtener información bastante importante de nuestro dataset, utilizando el método **info()**

```
Python  
df.info()
```

Esta operación muestra:

- cantidad de registros;
- nombres de columnas;
- valores no nulos;
- tipos de datos;
- Uso aproximado de memoria.

7. Estadísticas rápidas: Para columnas numéricas, podemos usar:

```
Python  
df.describe()
```

Obtendremos valores como:

- cantidad;
- promedio;
- desviación estándar;
- mínimo;
- máximo;
- percentiles.

8. Seleccionar columnas: Con pandas, podemos seleccionar directamente una sola columna:

```
Python  
df["producto"]
```

Y como resultado, obtendremos una serie. También podemos elegir varias columnas al mismo tiempo

Python

```
df[[ "producto", "precio" ]]
```

Esto produce un nuevo DataFrame.

9. Eliminar columnas innecesarias: Los datasets reales muchas veces contienen información que no necesitamos.

Por ejemplo: Imaginemos que nuestro dataset contiene las siguientes columnas:

- id
- producto
- precio
- cantidad
- fecha
- comentario_interno
- debug
- campo_temporal

Podemos seleccionar solamente las columnas necesarias:

Python

```
df = df[[ "id", "producto", "precio", "cantidad", "fecha" ]]
```

Otra posibilidad es eliminar columnas:

Python

```
df = df.drop( columns=[ "comentario_interno", "debug",  
"campo_temporal" ] )
```

Desde la perspectiva de Ingeniería de Datos esto resulta importante para, por ejemplo:

- disminuir datos innecesarios
- simplificar pipelines
- reducir almacenamiento
- evitar transportar información que no será utilizada.

10. Filtrar Registros:

En pandas, podemos utilizar condiciones para filtrar el contenido de una columna:

Python

```
df["precio"] > 10000
```

Como resultado obtendremos una serie con valores booleanos, algo parecido a esto:

precio

True

False

False

True

Sin embargo, si lo combinamos con:

Python

```
df[df["precio"] > 10000]
```

Todos aquellos valores True, serán los que quedarán, el resto en False, serán descartados.

Podemos también combinar varias condiciones para realizar los filtros, por ejemplo:

Python

```
df[(df["precio"] > 100000) & (df["cantidad"] > 0)]
```

Donde:

& → AND

| → OR

~ → NOT

Muy parecido a lo que hacíamos al principio con JavaScript.

11. Valores faltantes: En datasets reales, es extremadamente común encontrarse con valores faltantes. En pandas son representados como **NaN**:

Ejemplo:

producto	precio
Notebook	850000
Mouse	NaN
Teclado	35000

Existe un método llamado **isna()** que nos permite detectarlos

Python

```
df.isna()
```

Sin embargo, con este método obtendremos un dataframe con valores booleanos.

Lo que se suele hacer es combinar con el método **.sum()**, donde obtendremos algo así como esto:

producto	0
precio	12
cantidad	3

Así podemos conocer rápidamente cuántos valores faltantes existen por columna.

12. Eliminar valores faltantes: Podemos eliminar los registros faltantes utilizando un método llamado **dropna()**. Sin embargo, no es recomendado utilizar indiscriminadamente, ya que puede provocar la pérdida innecesaria de información.

Python

```
df.dropna()
```

También podemos especificar columnas críticas:

Python

```
df = df.dropna(subset=[ "producto", "precio" ])
```

Ahora solamente serán eliminadas las filas donde **producto** o **precio** sean nulos.

13. Reemplazar valores faltantes: Existe un método en pandas que nos permite reemplazar los valores faltantes **fillna()**:

Python

```
df["cantidad"].fillna(0)
```

En este caso, estamos reemplazando todos aquellos valores **NaN** por el 0.

También podríamos combinarlo con otros métodos, por ejemplo:

Python

```
df["precio"] = df["precio"].fillna(df["precio"].mean())
```

o lo correcto sería:

Python

```
promedio = df["cantidad"].mean()

df = df["cantidad"].fillna(promedio)
```

14. Registro de duplicados: Otra situación habitual es recibir registros duplicados. Pandas nos provee de un método bastante útil para esto **df.duplicated()**.

Python

```
df.duplicated()
```

Esto nuevamente nos devuelve un dataframe con valores booleanos. Pero podemos combinarlo con el método **sum()**.

Python

```
df.duplicated().sum()
```

También podemos eliminarlos con **df.drop_duplicates()**

Python

```
df = df.drop_duplicates()
```

También podemos considerar solamente una columna o columnas en específico:

Python

```
df = df.drop_duplicates(
    subset=["id"]
)
```

15. Normalizar texto

Uno de los problemas más frecuentes en pipelines de datos es encontrar categorías escritas de diferentes maneras. Con pandas, podemos normalizarlas de la siguiente forma:

Python

```
df["ciudad"] = (df["ciudad"].str.strip().str.lower())
```

Con esto, quitamos los espacios y colocamos el contenido de esta columna a minúsculas.

16. Reemplazar valores: También podemos corregir categorías conocidas:

Python

```
df["ciudad"] = df["ciudad"].replace({  
    "fsa": "formosa",  
    "formoza": "formosa",  
    "resis": "resistencia"  
})
```

Esto puede formar parte de una etapa de **normalización** o de **transformación**.

17. Conversión de tipos: Pandas tiene varios métodos para hacer conversiones de tipos. Supongamos que queremos convertir los valores de una columna precio al tipo numérico:

Python

```
df["precio"] = pd.to_numeric(df["precio"])
```

Esto intentará convertir todos los valores al tipo numérico. Sin embargo, si encuentra un valor que no puede convertirse a numérico como por ejemplo un "asd", lanzará una excepción.

Podemos combinarla con el parámetro `errors="coerce"`, para que aquellos valores que no sea posible convertirlos a números, se conviertan directamente a NaN.

Python

```
df["precio"] = pd.to_numeric(df["precio"], errors="coerce")
```

También existe el método `.astype()`. A diferencia `to_numeric()`, este pide que como parámetro especifiquemos el tipo de dato a convertir, por ejemplo:

Python

```
df["precio"] = df["precio"].astype("int")
```

Algo a tener en cuenta es que, si no es posible convertir todos los valores de la columna, nos lanzará una excepción.

18. Conversión a fechas: Las fechas son particularmente importantes en la ingeniería de datos. Un dataset podría contener:

2026-08-21

2026/08/22

23-08-2026

fecha incorrecta

Podemos intentar convertir los valores con el método `to_datetime()`

Python

```
df["fecha"] = pd.to_datetime(df["fecha"], errors="coerce")
```

Aquellos valores que no sea posible convertir a datetime, pasarán a ser NaT

También podemos especificar el formato:

Python

```
df["fecha"] = pd.to_datetime(df["fecha"], format="%y -m% -%d", errors="coerce")
```

Con este formato, estamos especificando que vamos a convertir fechas como por ejemplo: 2026-06-01

Directivas de formato más comunes

- %Y: Año con 4 dígitos (ej. 2026).
- %m: Mes con dos dígitos (01 al 12).
- %d: Día del mes con dos dígitos (01 al 31).
- %H: Hora en formato de 24 horas (00 al 23).
- %M: Minutos (00 al 59).
- %S: Segundos (00 al 59).

19. Extraer información de fechas: Una vez que una columna ya posea el tipo de fecha adecuado, podemos extraer sus componentes:

Python

```
df["anio"] = df["fecha"].dt.year  
df["mes"] = df["fecha"].dt.month  
df["dia"] = df["fecha"].dt.day
```

Obtendremos un resultado como esto:

Python

```
fecha = 2026-08-26  
año = 2026  
mes= 8  
dia = 26
```

20. Crear columnas nuevas: Una de las operaciones más frecuentes en un pipeline es crear información derivada. Supongamos que tenemos una columna precio y una columna cantidad, basados en el resultado de la multiplicación de ambos, queremos obtener el total:

Python

```
df["total"] = ( df["precio"] * df["cantidad"] )
```

Obtendremos ahora:

producto	precio	cantidad	total
----------	--------	----------	-------

Mouse	15000	3	45000
-------	-------	---	-------

21. Ordenar datos:

Podemos ordenar registros utilizando un método llamado **sort_values()**

Python

```
df.sort_values( by="precio" ) #orden ascendente
```

o

Python

```
df.sort_values( by="precio", ascending=False ) #orden descendente
```

También podemos ordenar utilizando múltiples columnas:

Python

```
df.sort_values(by=[ "ciudad", "fecha" ])
```

22. Agrupar información: Una operación extremadamente importante es `groupby()`:

Supongamos:

ciudad	total
Formosa	15000
Formosa	25000
Clorinda	10000
Clorinda	30000

Podemos calcular ventas totales por ciudad:

```
Python  
df.groupby("ciudad")["total"].sum()
```

Resultado:

Clorinda	40000
Formosa	40000

Combinar datasets: En ingeniería de datos frecuentemente necesitamos combinar información proveniente de distintas fuentes:

Por ejemplo:

clientes.csv

cliente_id	nombre
1	Ana
2	Carlos

ventas.csv

venta_id	cliente_id	total
101	1	5000
102	2	9000

Podemos combinarlos usando el método `.merge()`

Python

```
resultado = pd.merge( ventas, clientes, on="cliente_id" )
```

El resultado sería:

venta_id	cliente_id	total	nombre
101	1	5000	Ana
102	2	9000	Carlos

Esta operación es conceptualmente similar a un: JOIN de SQL.

23. Exportar resultados: Una vez aplicado las transformaciones y validaciones correspondientes, ya podemos almacenarla la información nuevamente:

CSV: con el método `to_csv()`

Python

```
df.to_csv("ventas_limpias.csv", index=False )
```

JSON: con el método `to_json()`

Python

```
df.to_json("ventas_limpias.json", index=False )
```

Excel: con el método `to_excel()`

Python

```
df.to_excel("ventas_limpias.xlsx", index=False )
```